ПРОЕКТНАЯ ПРАКТИКА В ОБЛАСТИ ИИ · КОНТРОЛЬНАЯ ТОЧКА 2

ИИ-ассистент по лабораторному практикуму физики НИЯУ МИФИ: что сделано к КП2

Команда №43 «Deep Learning Poor Eating»

Саитов Илья · Масляев Вячеслав · Юнусов Ибрагим · Грук Павел · Шарипов Оскар

Агенты: Расчётчик, Экзаменатор, Консультант (поиск по методичкам), Проверяющий, Диспетчер

Что планировали на КП1 и что сделано

сентябрь

Старт

команда, тема, роли, архитектура, КП1

сделано

6–19 окт

Данные и каркас

репозиторий, API и чат есть; методички МИФИ в базе — ещё нет

частично

20 окт – 4 нояб

Агенты v1

Расчётчик, Экзаменатор, поиск по методичкам — прототипы

частично

10–11 нояб

КП2

план: Диспетчер + 3 агента и метрики против baseline

частично

6–19 нояб

Проверяющий

Input Guard и Source Judge уже есть; память слабых тем готова

начато раньше

20 нояб – 3 дек

Надёжность

защита от инъекций, пилот на студентах, трейсинг и цена

впереди

4–14 дек

Финал

итоговые метрики, запуск одной командой, запись демо

впереди

15 дек

КП3

финальная защита, живое демо

впереди

Какие компоненты уже работают

Чат
Streamlit
сделано

API
FastAPI
сделано

Диспетчер
граф LangGraph, выбор агента
уточнить

Расчётчик
таблица / фото → погрешности, МНК, график
сделано

Экзаменатор
вопросы к допуску, оценка, память слабых тем
сделано

Поиск
по методичкам: модуль manual_search, PR в main
частично

Проверяющий
Input Guard (инъекции) · Source Judge (опора ответа на источники, LLM + Pydantic)
v1

Код

Общий репозиторий команды
[ссылка — добавить]

Расчётчик и поиск
github.com/Kolomkik123/mephilaborant

Экзаменатор, API и чат
github.com/mva17/examiner-agent

КОНКРЕТНЫЙ ВКЛАД КАЖДОГО УЧАСТНИКА

У каждого — свой агент

Саитов Илья
Расчётчик

- таблица текстом или фото → расчёт в Python
- проверка таблицы, единицы СИ, размерность
- повторные измерения, погрешности, МНК, график
- поиск формул в PDF методички

Масляев Вячеслав
Экзаменатор + API и чат

- граф LangGraph: тема → поиск → проверка релевантности
- вопросы со ссылкой на страницу, оценка, уточнение
- память слабых тем; FastAPI и Streamlit
- 67 автотестов, скрипт бенчмарка ruMMLU

Шарипов Оскар
Консультант + поиск

- поиск по методичкам — модуль modules/manual_search
- отдельная ветка feature/search, PR в main
- файлы Расчётчика не затронуты

Юнусов Ибрагим
Проверяющий

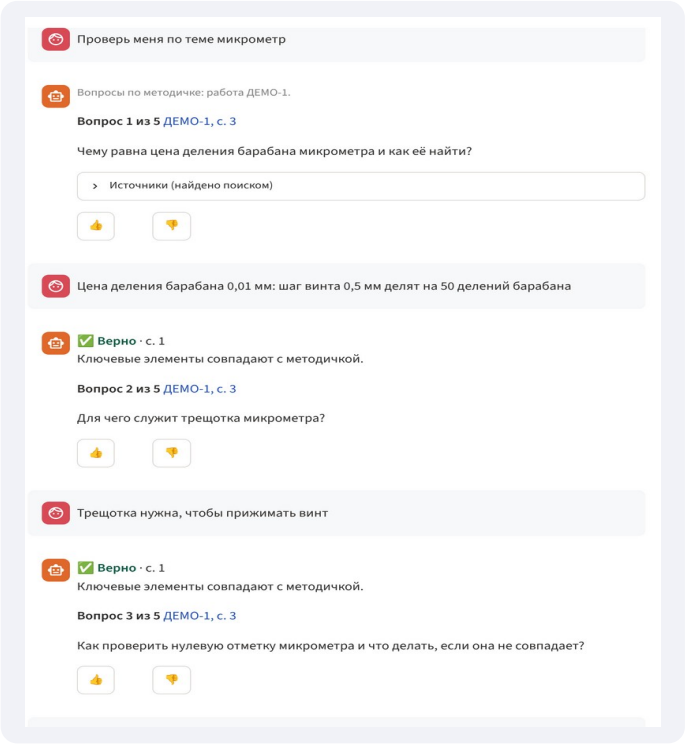
- Input Guard: поиск prompt injection (regex)
- Source Judge: проверка утверждений по источникам (LLM)
- структурированный ответ по Pydantic-схеме

Грук Павел
Диспетчер + архитектура

[Павел: 2–3 пункта, что сделано]

Как проверить вклад
у каждого своя папка и свои коммиты; модули попадают в общий main через ветку и pull request

Экзаменатор в чате



Тема → поиск в методичке
проверка, что найдено именно по теме; иначе — новый запрос

Вопрос со ссылкой на страницу
сначала «Контрольные вопросы»; вне базы — пометка «не из методички»

Оценка ответа
верно / частично / неверно + объяснение; на неполный — уточнение

Память слабых тем
в новой сессии сначала вопросы с прошлыми ошибками

Скриншот на демо-модели без ключа; тексты в базе — ДЕМО, не методички МИФИ

Что уже проверено и на чём

Агент	Метрика из КП1 · цель	Что проверено сейчас	Статус
Экзаменатор	совпадение оценки с эталоном на ruMMLU (физика) · ≥ 85%	67 автотестов без ключа: граф, API, поиск, память, инъекции; скрипт бенчмарка против «LLM без эталона»	**тесты ✓, число — после прогона**
Расчётчик	верные расчёты · ≥ 95%; пойманные промахи · ≥ 90%	проверочный набор из 12 синтетических эталонов (eval/calculations.json); автотесты расчётчика	**набор готов**
Проверяющий	отражённые атаки (deepset/prompt-injections) · ≥ 95%	Source Judge выдаёт ответ по Pydantic-схеме, демо-сценарий: verdict pass; найден пробел Input Guard → набор regex расширен	**демо ✓**
Поиск	нужная работа в топ-5 · ≥ 85%	модуль выделен, PR в main	**впереди**
Диспетчер	верный выбор агента · ≥ 95%	**[Павел: вписать]**	**[вписать]**

Честно: чисел по заявленным метрикам качества против baseline ещё нет — скрипты и тестовые наборы готовы, прогоны на модели будут до консультаций 8–9 декабря.

Что изменилось и что дальше

Изменения плана

- КП2 сдвинулась с 5 на 10–11 ноября
- методичек МИФИ в базе пока нет: работаем на демо-текстах и образце PDF
- Проверяющий и память слабых тем начаты раньше плана
- модель меняется через base_url: Cloud.ru без VPN или OpenRouter

Риски

- модули в разных ветках → сборка в общий main через PR
- грант Cloud.ru → лимиты вызовов, прогон на 100 вопросах
- нет чисел качества → прогоны до 8–9 декабря
- формулы из сложной вёрстки PDF читаются с ошибками

Задачи до 15 декабря

- общий граф Диспетчера со всеми агентами
- методички МИФИ в ChromaDB
- метрики против baseline у каждого агента
- пилот на студентах, запуск одной командой, запись демо

Самооценка и замечания с КП1

Получилось

- у каждого свой модуль, вклад виден по коммитам
- два агента работают как прототипы с чатом
- есть тесты и проверочные наборы

Не успели

- общий граф со всеми агентами
- числа по метрикам против baseline
- настоящие методички МИФИ в базе

Что обсуждали на защите КП1

Вопрос или замечание → что сделали

[1. вписать замечание с КП1 → что сделано]

[2. вписать замечание с КП1 → что сделано]